


CS 188: Inteligência Artificial

Aprendizado por Reforço II



Instrutores: Peyrin Kao e Emma Pierson --- Universidade da Califórnia, Berkeley

Aprendizado por Reforço

§ Ainda assumimos um MDP:

§ Um conjunto de estados $s \in S$

Um conjunto de ações (por

estado) A § Um modelo $T(s,a,s')$

Uma função recompensa $R(s,a,s')$

§ Ainda procurando uma apólice $p(s)$



§ Nova reviravolta: não sei T ou R , então preciso testar ações

§ Grande ideia: Calcular todas as médias sobre T usando resultados amostrais

A História Até Agora: MDPs e RL

MDP Conhecido: Solução Offline

Objetivo

Calcule V^* , Q^* , p^*

Avalie uma política fixa p

Técnica

Valor / iteração de políticas

Avaliação de políticas

MDP desconhecido: Baseado em modelos

Objetivo

Calcule V^* , Q^* , p^*

Avalie uma política fixa p

Técnica

VI/PI com aproximadamente MDP

PE em aproximadamente MDP

MDP Desconhecido: Sem Modelo

Objetivo

Calcule V^* , Q^* , p^*

Avalie uma política fixa p

Técnica

Q-learning

Aprendizagem de Valores (Avaliação Direta, TDlearning)

Aprendizagem Livre de Modelos


§ Aprendizado sem modelo (diferença temporal)

§ Vivenciar o mundo através dos episódios

$$(s, a, r, s', a', r', s'', a'', r'', s'''' \dots)$$

§ Atualização estima cada transição a, r, s'

§ Com o tempo, as atualizações vão imitar as atualizações do Bellman



Q-Learning

§ Gostaríamos de fazer atualizações do valor Q para cada estado Q:

$$Q_{k+1}(s, a) \leftarrow$$

§ Mas não dá para calcular essa atualização sem saber T, R

§ Em vez disso, calcule a média conforme avançamos

§ Receber uma transição amostral

(s,a,r,s') § Esta amostra sugere

$$Q(s, a) \approx r + \gamma \max_{a'} Q(s', a')$$

§ Mas queremos fazer uma média sobre os resultados de

(s,a) (Por quê?) § Então mantenha uma média contínua

$$Q(s, a) \leftarrow (1 - \alpha)Q(s, a) + (\alpha) \left[r + \gamma \max_{a'} Q(s', a') \right]$$

Propriedades de Aprendizagem Q

§ Resultado incrível: Q-learning converge para uma política ótima — mesmo que você esteja agindo de forma subótima!

§ Isso é chamado de aprendizado fora de políticas

§ Ressalvas:


§ Você tem que explorar o suficiente
§ Você tem que, eventualmente, atingir a taxa de aprendizado pequeno o suficiente (ou você não converge)
§ ... mas não diminua muito rápido
§ Basicamente, no limite, não importa como você seleciona as ações (!)



Vídeo da Demonstração Q-Learning Auto Cliff Grid



Exploração vs. Exploração



Como explorar?


§ Vários esquemas para forçar a exploração

§ O mais simples: ações aleatórias (e-greedy)

§ A cada passo de tempo, jogue uma moeda
§ Com (pequena) probabilidade ϵ , aja aleatoriamente
§ Com (grande) probabilidade $1-\epsilon$, aja conforme a política atual

§ Problemas com ações aleatórias?

§ Você eventualmente explora o espaço, mas continua se debatendo depois que o aprendizado termina
§ Uma solução: diminuir ϵ ao longo do tempo
§ Outra solução: funções de exploração



Vídeo de Demonstração de Q-learning – Epsilon-Greedy – Crawler



Funções de Exploração

§ Quando explorar?

§ Ações aleatórias: explorar uma quantidade fixa
Ideia melhor: explorar áreas cuja negatividade não é (ainda) estabelecido, eventualmente parar de explorar

§ Função de exploração

§ Faz uma estimativa de valor que você e uma conta de visitas n , e retorna uma utilidade otimista, por exemplo, k/n

Atualização Geral de Q: $Q(s, a) \leftarrow_{\alpha} R(s, a, s') + \gamma \max_{a'} Q(s', a')$

Q-Update Modificado: $Q(s, a) \leftarrow_{\alpha} R(s, a, s') + \gamma \max_{a'} f(Q(s', a'), N(s', a'))$

§ Nota: isso propaga o "bônus" de volta para estados que levam a estados desconhecidos também!



Vídeo de Demonstração Q-learning – Função de Exploração – Crawler



Lamentar


§ Mesmo que você aprenda a política ideal, ainda cometerá erros ao longo do caminho!

§ Arrependimento é uma medida do custo total do seu erro: a diferença entre suas recompensas (esperadas), incluindo suboptimalidade juvenil e recompensas ótimas (esperadas)


Minimizar o arrependimento vai além de aprender a ser ótimo – requer Aprendendo de forma ótima a ser

ótimo

Exemplo: exploração aleatória e As funções de exploração acabam sendo ótimas, mas a exploração aleatória tem mais arrependimento



Q-Learning Aproximado



Generalização entre Estados

§ O Q-Learning básico mantém uma tabela com todos os q-valores
§ Em situações realistas, não podemos aprender sobre todos os estados!

§ Muitos estados para visitá-los todos em treinamento
§ Muitos estados para guardar as q-tables na memória



§ Em vez disso, queremos generalizar:

§ Aprenda sobre um pequeno número de estados de treinamento a partir da experiência
§ Generalize essa experiência para novas situações semelhantes
§ Essa é uma ideia fundamental no aprendizado de máquina, e vamos vê-la repetidas vezes




Exemplo: Pacman

Vamos supor que descobrimos pela experiência que esse estado nada sobre esse estado: é ruim:



Ou até mesmo este!



Vídeo da demonstração do Q-Learning Pacman –

Tiny – Assista a Todos



Vídeo da demonstração do Q-Learning Pacman – Tiny – Trem Silencioso



Vídeo de demonstração do Q-Learning Pacman –
— Complicado – Assista a todos




Representações Baseadas em Características

§ Solução: descrever um estado usando um vetor de características (propriedades)
§ Características são funções de estados para números reais (frequentemente 0/1) que capturam propriedades importantes do estado
§ Características de exemplo:
§ Distância ao fantasma mais próximo
§ Distância ao ponto mais próximo

§ Número de fantasmas
§ 1 / (dist to dot)
§ Pacman está em um túnel? (0/1)
§ etc.
§ É exatamente o estado neste slide?

§ Também pode descrever um estado q (s, a) com características (por exemplo, ação se aproxima do alimento)



Funções de valor lineares

§ Usando uma representação de características, podemos escrever uma função q (ou função valor) para qualquer estado usando alguns pesos:

$$V(s) = w_1 f_1(s) + w_2 f_2(s) + \dots + w_n f_n(s)$$

$$Q(s, a) = w_1 f_1(s, a) + w_2 f_2(s, a) + \dots + w_n f_n(s, a)$$

§ Meta: aprender os pesos w

§ Vantagem: nossa experiência é resumida em alguns números poderosos

§ Desvantagem: estados podem compartilhar características, mas na verdade ser muito diferentes em valor!

Q-Learning Aproximado

$$Q(s, a) = w_1 f_1(s, a) + w_2 f_2(s, a) + \dots + w_n f_n(s, a)$$

§ Q-aprendizagem com funções Q lineares:

$$\text{transition} = (s, a, r, s')$$

$$\text{difference} = \left[r + \gamma \max_{a'} Q(s', a') \right] - Q(s, a)$$


$$Q(s, a) \leftarrow Q(s, a) + \alpha [\text{difference}]$$

Q exatos

$$w_i \leftarrow w_i + \alpha [\text{difference}] f_i(s, a)$$


Q aproximados

§ Interpretação intuitiva: Ajuste os pesos das características ativas
§ Por exemplo, se algo inesperadamente ruim acontecer, culpe as características que estavam em: não prefiro todos os estados com as características daquele estado
§ Justificativa formal: mínimos quadrados online



Exemplo: Q-Pacman

$$Q(s, a) = 4.0 f_{DOT}(s, a) - 1.0 f_{GST}(s, a)$$



difference = -501 $\Rightarrow$

$$w_{DOT} \leftarrow 4.0 + \alpha [-501] 0.5$$


$$w_{GST} \leftarrow -1.0 + \alpha [-501] 1.0$$

$$Q(s, a) = 3.0 f_{DOT}(s, a) - 3.0 f_{GST}(s, a)$$


Vídeo de Demo Aproximado Q-Learning -- Pacman



Q-Aprendizagem e Mínimos Quadrados




Aproximação Linear: Regressão*



Previsão: Previsão:


$$\hat{y} = w_0 + w_1 f_1(x)$$



$$\hat{y}_i = w_0 + w_1 f_1(x) + w_2 f_2(x)$$

Otimização: Mínimos Quadrados*


$$\text{total error} = \sum_i (y_i - \hat{y}_i)^2 = \sum_i \left(y_i - \sum_k w_k f_k(x_i) \right)^2$$



Minimizando erro*

Imagine que tivéssemos apenas um ponto x , com características $f(x)$, valor-alvo y e pesos w :

$$\text{error}(w) = \frac{1}{2} \left(y - \sum_k w_k f_k(x) \right)^2$$
$$\frac{\partial \text{error}(w)}{\partial w_m} = - \left(y - \sum_k w_k f_k(x) \right) f_m(x)$$
$$w_m \leftarrow w_m + \alpha \left(y - \sum_k w_k f_k(x) \right) f_m(x)$$




Atualização aproximada do q explicado:

$$w_m \leftarrow w_m + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right] f_m(s, a)$$


"Alvo"

"previsão"

Overfitting: Por que limitar a capacidade pode ajudar*



Busca de Políticas



Busca de Políticas

§ Problema: muitas vezes as políticas baseadas em recursos que funcionam bem (vencer jogos, maximizar utilidades) não são as que melhor se aproximam do V / Q

§ Por exemplo, suas funções de valor do projeto 2 provavelmente eram estimativas horríveis de recompensas futuras, mas ainda assim produziram boas decisões

§ Prioridade do Q-learning: aproximar Q-valores (modelagem)

§ Prioridade de seleção de ação: acertar a ordem dos Q-valores (previsão)

§ Veremos essa distinção entre modelagem e previsão novamente mais adiante no curso

§ Solução: aprenda políticas que maximizam recompensas, não os valores que as preveem

§ Pesquisa de políticas: comece com uma solução ok (por exemplo, Q-learning) e depois ajuste por subida de ladeira nos pesos das características

Busca de Políticas

§ Busca de políticas mais simples:

§ Comece com uma função de valor linear inicial ou função Q
§ Aumente e desça o peso de cada característica e veja se sua política está melhor do que antes

§ Problemas:

§ Como saber se a política melhorou?§

Precisamos exibir muitos episódios de amostra!§


Se há muitos recursos, isso pode ser impraticável

§ Métodos melhores exploram a estrutura de antecipação, amostram com sabedoria, alteram múltiplos parâmetros...


RL: Voo de Helicóptero



RL: Aprendendo Locomoção



RL: Aprendendo Futebol




RL: Manipulação de Aprendizagem



RL: NASA SUPERball



RL: Manipulação In-Hand



OpenAI: Dactyl

Treinado com randomização por domínio

Muitas outras aplicações do aprendizado por reforço

§ Educação § Saúde § Processamento de
linguagem natural § Controle da rede
elétrica (e controle de data center) §
Transporte

