


CS 188: Inteligência Artificial


Aprendizado por Reforço




Instrutores: Emma Pierson e Peyrin Kao

Universidade da Califórnia, Berkeley

Aprendizado por Reforço




Você pode ensinar um gato a brincar de buscar? Iteração 1




Você pode ensinar um gato a brincar de buscar? Iteração 2



Você pode ensinar um gato a brincar de buscar? Iteração 3



Aprendizado por Reforço



- Ideia básica: ▪ Receba feedback na forma de recompensas ▪ A utilidade do agente é definida pela função ▪ de recompensa Deve (aprender a) agir para maximizar as recompensas ▪ esperadas Todo aprendizado é baseado em amostras observadas de resultados!

Exemplo: Aprendendo a Andar



Inicial



Um Julgamento de
Aprendizagem



Após Aprender [1K Trials]

Exemplo: Aprendendo a Andar



Inicial

Exemplo: Aprendendo a Andar



Formação

Exemplo: Aprendendo a Andar




Terminado

Exemplo: Enrolamento lateral



O Rastejante!



Vídeo do bot Demo Crawler



Aprendizado por Reforço


- Ainda assuma um processo de decisão de Markov (MDP):
 - Um conjunto de estados $s \in S$
 - Um conjunto de ações (por estado)
 - Um modelo $T(s,a,s')$
 - Uma função de recompensa $R(s,a,s')$
- Ainda procurando uma política π



Nova ▪ reviravolta: não sei T ou R

- Ou seja, não sabemos quais estados são bons ou o que as ações fazem. Precisamos realmente testar ações e estados para aprender

Offline (MDPs) vs. Online (RL)




Solução Offline



Aprendizagem Online

Aprendizagem Baseada em Modelos




Aprendizagem Baseada em Modelos

- Ideia Baseada em Modelo: ▪ Aprenda um modelo aproximado baseado em experiências▪ Resolva valores como se o modelo aprendido estivesse correto▪ Passo 1: Aprenda o modelo▪ MDP empírico Conte resultados s' para cada s , a ▪ Normalize para dar uma estimativa de▪ Descubra cada quando experimentarmos (s , a , s')▪ Passo 2: Resolva o MDP▪ aprendido Por exemplo, Iteração de valor de uso, como antes



Exemplo: Aprendizagem Baseada em Modelos

Política de Entrada Episódios Observados (Treinamento) Modelo Aprendido



Assuma: $\gamma = 1$

Episódio 1 Episódio 2

B, leste, C, -1C,
leste, D, -1D,
saída, x, +10

B, leste, C, -1C,
leste, D, -1D,
saída, x, +10

Episódio 3 Episódio 4

E, norte, C, -1C,
leste, D, -1D,
saída, x, +10

E, norte, C, -1C,
leste, A, -1A,
saída, x, -10

$T(s, a, s')$.

$T(B, \text{leste}, C) = 1,00$
 $T(C, \text{leste}, D) = 0,75$
 $T(C, \text{leste}, A) = 0,25$

...

$R(s, a, s')$.

$R(B, \text{leste}, C) =$
 $-1R(C, \text{leste}, D) =$
 $-1R(D, \text{saída}, x) = +10$

...

Exemplo: Idade Esperada

Objetivo: Calcular a idade esperada dos alunos do CS188

P(A) Conhecida

$$E[A] = \sum_a P(a) \cdot a = 0.35 \times 20 + \dots$$

Sem P(A), coletar amostras [a1, a2, ... aN]

P(A) desconhecido: "Baseado em modelos"

Por que isso funciona? Porque

eventualmente você
Aprenda o que é certo
modelo.

$$\hat{P}(a) = \frac{\text{num}(a)}{N}$$

$$E[A] \approx \sum_a \hat{P}(a) \cdot a$$


P(A) desconhecido: "Sem modelos"

$$E[A] \approx \frac{1}{N} \sum_i a_i$$


Por que isso funciona? Porque aparecem amostras com as frequências certas (você vê o # à direita em

cada caixa)

Aprendizagem Livre de Modelos




Aprendizado por Reforço Passivo



Aprendizado por Reforço Passivo

- Tarefa simplificada: avaliação de políticas
- Entrada: uma política fixa $\pi(s)$
- Você não conhece as transições $T(s,a,s')$
- Você não conhece as recompensas $R(s,a,s')$
- Objetivo: aprender os valores de estado
- Neste caso: o aprendiz está "acompanhando a jornada"
- Sem escolha sobre quais ações tomar
- Apenas execute a política e aprenda com a experiência
- Isso NÃO é planejamento offline!
- Você realmente toma ações no mundo.



Avaliação Direta

- Objetivo: Calcular valores para cada estado sob π ▪ Ideia:

Fazer uma média conjunta dos valores amostrais observados

- Aja de acordo com π ▪ Toda vez que visitar um estado, escreva o que o


A soma das recompensas com desconto acabou sendo▪ a média dessas amostras

- Isso é chamado de avaliação direta



Exemplo: Avaliação Direta

Política de Entrada Episódios Observados (Treinamento) Valores de Saída



Assuma: $\gamma = 1$

Episódio 1 Episódio 2


B, leste, C, -1C,
leste, D, -1D,
saída, x, +10

B, leste, C, -1C,
leste, D, -1D,
saída, x, +10

Episódio 3 Episódio 4

E, norte, C, -1C,
leste, D, -1D,
saída, x, +10

E, norte, C, -1C,
leste, A, -1A,
saída, x, -10



Problemas com a Avaliação Direta

- O que há de bom na avaliação direta?
 - É fácil de entender. Não requer conhecimento de T, R. Eventualmente calcula os valores médios corretos, usando apenas transições de amostra
- O que de ruim nisso?
 - Ele desperdiça informações sobre conexões de estado. Cada estado deve ser aprendido separadamente. Então, leva muito tempo para aprender

Valores de Saída

	-10 Um	
+8+4 A.C		+10 D
	-2 E	


Se tanto a B&E como a Cunder vão para essa política, como pode Os valores deles seriam diferentes?

Por que não usar a avaliação de políticas?

- Atualizações simplificadas de Bellman calculam V para uma política fixa: ▪ a cada rodada, substitua V por uma camada de antevisão de um passo sobre V

$$V_0^\pi(s) = 0$$

$$V_{k+1}^\pi(s) \leftarrow$$




- Essa abordagem explorou totalmente as conexões entre os estados. Infelizmente, precisamos de T e R para isso!
- Pergunta-chave: como podemos fazer essa atualização para V sem conhecer T e R ? ▪ Em outras palavras, como fazer uma média ponderada sem conhecer os pesos?

Por que não usar a avaliação de políticas?

- Atualizações simplificadas de Bellman calculam V para uma política fixa: ▪ a cada rodada, substitua V por uma camada de antevisão de um passo sobre V

$$V_0^\pi(s) = 0$$

$$V_{k+1}^\pi(s) \leftarrow \sum_{s'} T(s, \pi(s), s') R(s, \pi(s), s') V_k^\pi(s')$$



- Essa abordagem explorou totalmente as conexões entre os estados. Infelizmente, precisamos de T e R para isso!
- Pergunta-chave: como podemos fazer essa atualização para V sem conhecer T e R ? ▪ Em outras palavras, como fazer uma média ponderada sem conhecer os pesos?

Por que não usar a avaliação de políticas?


- Atualizações simplificadas de Bellman calculam V para uma política fixa: ▪ a cada rodada, substitua V por uma camada de antevisão de um passo sobre V

$$V_0^\pi(s) = 0$$

$$V_{k+1}^\pi(s) \leftarrow \sum_{s'} T(s, \pi(s), s') [$$

Probability of ending up in s' if

- Essa abordagem explorou totalmente as conexões entre os estados. Infelizmente, precisamos de T e R para isso!
- Pergunta-chave: como podemos fazer essa atualização para V sem conhecer T e R ? ▪ Em outras palavras, como fazer uma média ponderada sem conhecer os pesos?




Por que não usar a avaliação de políticas?

- Atualizações simplificadas de Bellman calculam V para uma política fixa: ▪ a cada rodada, substitua V por uma camada de antevisão de um passo sobre V

$$V_0^\pi(s) = 0$$

$$V_{k+1}^\pi(s) \leftarrow \sum_{s'} T(s, \pi(s), s') [R(s, \pi(s), s') + \gamma V_k^\pi(s')]$$

Utility of ending up in s' if you




- Essa abordagem explorou totalmente as conexões entre os estados. Infelizmente, precisamos de T e R para isso!
- Pergunta-chave: como podemos fazer essa atualização para V sem conhecer T e R ? ▪ Em outras palavras, como fazer uma média ponderada sem conhecer os pesos?

Por que não usar a avaliação de políticas?

- Atualizações simplificadas de Bellman calculam V para uma política fixa: ▪ a cada rodada, substitua V por uma camada de antevisão de um passo sobre V

$$V_0^\pi(s) = 0$$

$$V_{k+1}^\pi(s) \leftarrow \sum_{s'} T(s, \pi(s), s') [R(s, \pi(s), s') + \gamma V_k^\pi(s')]$$



- Essa abordagem explorou totalmente as conexões entre os estados. Infelizmente, precisamos de T e R para isso!
- Pergunta-chave: como podemos fazer essa atualização para V sem conhecer T e R ? ▪ Em outras palavras, como fazer uma média ponderada sem conhecer os pesos?

Avaliação de Políticas Baseada em Exemplo?

- Queremos melhorar nossa estimativa de V calculando estas médias:

$$V_{k+1}^{\pi}(s) \leftarrow \sum_{s'} T(s, \pi(s), s') [R(s, \pi(s), s') + \gamma V_k^{\pi}(s')]$$

- Ideia: Colete amostras dos resultados (fazendo a ação!) e da média


$$sample_1 = R(s, \pi(s), s'_1) + \gamma V_k^{\pi}(s'_1)$$

$$sample_2 = R(s, \pi(s), s'_2) + \gamma V_k^{\pi}(s'_2)$$

...


$$sample_n = R(s, \pi(s), s'_n) + \gamma V_k^{\pi}(s'_n)$$

$$V_{k+1}^{\pi}(s) \leftarrow \frac{1}{n} \sum_i sample_i$$




Quase! Mas não podemos voltar tempo para pegar uma amostra Após a amostra do estado S .

Aprendizagem por Diferença Temporal



Aprendizagem por Diferença Temporal

- Grande ideia: aprenda com cada experiência!
 - Atualize $V(s)$ toda vez que experimentarmos uma transição (s, a, s', r)
 - Resultados prováveis s' contribuirá com atualizações com mais frequência
- Aprendizado por diferença temporal de valores
 - Política ainda fixa, ainda fazendo avaliação!
 - Mova valores em direção ao valor do sucessor que ocorrer: média móvel



Exemplo de $V(s)$: $sample = R(s, \pi(s), s') + \gamma V^\pi(s')$

Atualização para $V(s)$: $V(s) \leftarrow (1 - \alpha)V^\pi(s) + (\alpha)sample$

Mesma atualização: $V^\pi(s) \leftarrow V^\pi(s) + \alpha(sample - V^\pi(s))$

Média Móvel Exponencial

- Média móvel exponencial

- A atualização da interpolação em execução: $(1 - \alpha) \cdot \bar{x}_{n-1} + \alpha \cdot x_n$

Torna as amostras recentes mais importantes:

$$\bar{x}_n = \frac{x_n + (1 - \alpha) \cdot x_{n-1} + (1 - \alpha)^2 \cdot x_{n-2} + \dots}{1 + (1 - \alpha) + (1 - \alpha)^2 + \dots}$$

- Esquece o passado (valores do passado distante estavam errados mesmo)
- A taxa de aprendizado decrescente (alfa) pode fornecer médias convergentes

Exemplo: Aprendizagem por Diferença Temporal

Estados

	Um	
A.C		D
	E	

Suponha: $\gamma = 1$, $\alpha = 1/2$

Transições observadas

B, leste, C, -2

C, leste, D, -2

	0	
00		8
	0	

	0	
-10		8
	0	

	0	
-13		8
	0	

$$V^\pi(s) \leftarrow (1 - \alpha)V^\pi(s) + \alpha [R(s, \pi(s), s') + \gamma V^\pi(s')]$$

$$\text{Novo } V(B) \leftarrow 0,5 * 0 + 0,5[-2 + 1 * 0] = -1$$

$$\text{Novo } V(C) \leftarrow 0,5 * 0 + 0,5[-2 + 1 * 8] = 3$$

Problemas com a Aprendizagem de Valores

TD


- A aprendizagem do valor TD é uma forma sem modelos de fazer avaliação de políticas, imitando

Bellman atualiza com médias amostrais em execução. No entanto, se quisermos transformar valores em uma (nova) política, estamos perdidos:


$$\pi(s) = \arg \max_a Q(s, a)$$

$$Q(s, a) = \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V(s')]$$

- Ideia: aprender valores Q, não valores π. Torna a seleção de ações livre de modelos também!



Aprendizado por Reforço Ativo



Aprendizado por Reforço Ativo

- Aprendizado por reforço completo: políticas ótimas (como iteração de valores) ▪ Você não conhece as transições $T(s,a,s')$
 - Você não conhece as recompensas $R(s,a,s')$ ▪ Você escolhe as ações agora ▪ Objetivo: aprenda a política/valores ▪ ótimos
- Neste caso: ▪ o aprendiz faz escolhas! ▪ Troca fundamental: exploração vs. exploração ▪ Isso NÃO é planejamento offline! Você realmente age no mundo e descobre o que acontece...



Desvio: Iteração Q-Value

- Iteração de valores: encontre valores sucessivos (limitados por profundidade) Comece com $V_0(s) = 0$, que sabemos que está correto. Dado V_k , calcule os valores de profundidade $k+1$ para todos os estados:

$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_k(s')]$$

- Mas os valores de Q são mais úteis, então calcule-os em vez disso: comece com $Q_0(s,a) = 0$, que sabemos que está correto. Dado Q_k , calcule a profundidade de $k+1$ valores q para todos os q-estados:

$$Q_{k+1}(s, a) \leftarrow \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma \max_{a'} Q_k(s', a')]$$

Another way of writing $V_k(s')$

Q-Learning

- Q-Learning: iteração baseada em Q-value baseada em amostras

$$Q_{k+1}(s, a) \leftarrow \sum_{s'} T(s, a, s') \left[R(s, a, s') + \gamma \max_{a'} Q_k(s', a') \right]$$

- Aprenda os valores $Q(s,a)$ conforme avança

- Receba uma amostra (s,a,s',r) ▪


Considere sua estimativa antiga: ▪

Considere sua nova estimativa amostral:

$$sample = R(s, a, s') + \gamma \max_{a'} Q(s', a')$$

- Incorpore a nova estimativa em uma média contínua:

$$Q(s, a) \leftarrow (1 - \alpha)Q(s, a) + (\alpha) [sample]$$



[Demo: Q-learning – gridworld (L10D2)]

[Demo: Q-learning – crawler (L10D3)]

Vídeo de Demonstração Q-Learning -- Gridworld



$$sample = R(s, a, s') + \gamma \max_{a'} Q(s', a')$$

Vídeo de Demonstração Q-Learning -- Crawler



Propriedades de Aprendizagem Q

- Resultado impressionante: Q-learning converge para políticas ótimas — até mesmo

Se você está agindo de forma subótima!

- Isso é chamado de Avisos de aprendizagem▪ fora da política:

- Você precisa explorar o suficiente▪. Tem que, eventualmente, atingir a taxa de aprendizado.

pequeno o▪ suficiente ... Mas não diminuir muito rápido▪

Basicamente, no limite, não importa como você seleciona as ações (!)

